

Informe Final

Agente de Voz con IA para Seguimiento Postoperatorio

Tech Sphere Challenge 2026

Evidencia de proceso, prompts, configuraciones y capturas del demo

Repositorio: github.com/ValeriaCespedes/tech-sphere-challenge-2026-agente-postop

1. Resumen del proyecto

El proyecto implementa un agente de voz con IA para el seguimiento postoperatorio de pacientes. El agente conversa por voz con el paciente, interpreta síntomas descritos en lenguaje cotidiano y regional, responde con información fundamentada en un corpus clínico mediante RAG (retrieval-augmented generation), decide si un caso amerita escalar a personal médico, y genera un resumen estructurado al cierre de cada llamada.

La solución expone las dos superficies exigidas por el reto: una interfaz de llamada (navegador, con selector de paciente, micrófono y reproducción de audio) y una consola de administración de conocimiento (subir, listar y eliminar documentos del RAG en caliente, vía Streamlit).

Stack: FastAPI (orquestración), ChromaDB (base vectorial), Groq como proveedor de inferencia (Llama 3.3 70B Versatile para razonamiento y Whisper Large V3 para transcripción), y Kokoro TTS para síntesis de voz en español.

2. Declaración del modelo de lenguaje y justificación (G3)

Modelo utilizado: Llama 3.3 70B Versatile, servido vía Groq.

Este modelo se eligió por dos razones principales:

- Latencia ultra-baja: es un factor determinante en una conversación de voz en tiempo real, donde los silencios largos deterioran la experiencia del paciente.
- Continuidad de familia permitida: el modelo originalmente listado en las reglas del reto (Llama-3.1-70b-versatile) fue discontinuado por el proveedor durante la ventana de desarrollo del concurso. Según la nota de `stack-tecnico.md` "los modelos vencen, las familias no" Llama 3.3 70B Versatile es el sucesor vigente de esa misma familia dentro de Groq, por lo que se adoptó como reemplazo directo dentro de las reglas permitidas.

Alternativa evaluada y descartada: Google Gemini 1.5 Flash (código conservado en `src/gemini_client.py`, no usado en producción). Se descartó por mayor latencia frente a Groq y porque el modelo listado en la plataforma de Google también presentó discontinuidad durante el desarrollo del reto.


Modelo de transcripción (STT): Whisper Large V3, también vía Groq mismo proveedor que el LLM, lo que evita saltos de latencia entre servicios distintos.

Motor de síntesis de voz (TTS): Kokoro, ejecutado localmente en CPU (voz `ef_dora` en español). Es, según las métricas de la sección 7, el cuello de botella principal de la latencia total.

3. Arquitectura de la solución

El siguiente diagrama resume las cuatro capas de la solución: presentación (las dos superficies exigidas), aplicación (endpoints de FastAPI), módulos de dominio (`src/`), y las dependencias externas (nube, cómputo local y almacenamiento).

Arquitectura de la solución



Puntos clave de esta arquitectura:

- La consola de administración puede ingestar documentos directamente hacia ChromaDB, sin pasar por la capa de aplicación, lo que permite actualizar el conocimiento clínico en caliente.
- El endpoint POST /turno orquesta el ciclo completo de un turno de conversación: STT → triaje → RAG → TTS.
- La base vectorial (ChromaDB) ya viene pre-indexada con 8,644 chunks provenientes de 107 PDFs del corpus clínico.
- Los registros de llamadas (turnos, decisiones, métricas) se persisten como JSON en data/llamadas/.

4. Flujo de decisión del agente

El flujo de decisión describe cómo cada turno del paciente se clasifica en verde, amarillo, rojo o ambiguo, y cómo esa clasificación determina la respuesta y la posible escalación a personal médico.



La lógica de triaje combina el criterio del LLM con reglas duras: cuando el paciente reporta síntomas de alarma (p. ej. dificultad respiratoria, dolor torácico), las reglas duras refuerzan o corrigen la clasificación del modelo para minimizar el riesgo de un falso negativo, que es la falla más costosa en un contexto clínico.

5. Evidencia del proceso de desarrollo y pruebas

Esta sección documenta pruebas unitarias de los módulos de dominio, ejecutadas desde la terminal durante el desarrollo, antes de integrarlos a la interfaz de llamada.

5.1 Pruebas del módulo de respuesta con RAG (src/responder.py)

Primera prueba — se envió una pregunta relacionada con circuitos eléctricos para verificar el comportamiento del RAG frente a una consulta ambigua/fuera del dominio típico:

```
(.venv) PS ...\\ParticipantArtifacts> python -m src.responder  
Loading weights: 100%|████████████████████████████████████████| 199/199 [00:00<00:00, 5526.20it/s]
```

Respuesta generada:

```
"Un circuito RC de primer orden consiste en una resistencia R y un capacitor C conectados en serie o en paralelo con una fuente DC. Esto permite que el voltaje en el capacitor evolucione en el tiempo, describiendo una respuesta transitoria del sistema. Esto es lo que se menciona
```

en el informe sobre circuitos, si necesita más información o aclaraciones, puedo ofrecerle escalar a un experto en el tema."

Fuentes: [{'archivo': 'Informe Lab5Circuitos.pdf', 'ruta': 'consola_admin/Informe Lab5Circuitos.pdf'}]

Latencia: 0.94s | Tokens: {'input': 1330, 'output': 100}

Este resultado evidenció un problema: el RAG recuperó y respondió con contenido de un documento de prueba ajeno al corpus clínico ("Informe Lab5Circuitos.pdf", cargado desde la consola de administración), en lugar de reconocer que la pregunta estaba fuera del alcance clínico. Este hallazgo motivó reforzar el guardrail de "fuera de alcance" (ver evidencia adicional en la sección 6.3).

Segunda prueba misma sesión, consulta sobre un caso dentro del corpus clínico (cáncer colorrectal):

"Lo siento, pero no tengo información en el contexto proporcionado sobre circuitos RC de primer orden. Este tema parece estar fuera del alcance del diagnóstico, tratamiento y seguimiento del cáncer de colon y recto que se describe en el contexto. Si desea obtener información sobre su tratamiento o seguimiento, estaré encantado de ayudarlo, de lo contrario, puedo ofrecerle escalar su consulta a un profesional médico adecuado."

Fuentes: [{'archivo': 'Diagnóstico, estadificación, tratamiento y seguimiento del paciente adulto con

cáncer de colon en el Hospital Universitario Nacional de Colombia.pdf', ...},

{'archivo': 'GUÍA DE MANEJO PARA EL DIAGNÓSTICO, TRATAMIENTO, SEGUIMIENTO Y PALIACIÓN DEL CÁNCER


DE COLON Y RECTO.pdf', ...}]

Latencia: 1.02s | Tokens: {'input': 1386, 'output': 97}

Aquí el agente sí reconoce correctamente que la pregunta está fuera del contexto clínico cargado para ese escenario, cita las dos guías reales que sustentan el contexto disponible, y ofrece escalar el comportamiento esperado.

5.2 Selección de la voz (TTS)

Se generaron y compararon audios de prueba con las voces en español disponibles en Kokoro:



"Se evaluaron las 3 voces en español disponibles en Kokoro; se eligió ef_dora".

Nota registrada durante la prueba, pendiente de afinar más adelante: la respuesta del agente resultó un poco larga para una llamada de voz el propio README del reto advierte que las "respuestas largas" son inviábiles en un canal de voz. Se dejó como mejora de prompt a futuro, no bloqueante para la entrega.

5.3 Pruebas del módulo de triaje (src/decision.py)

Se probó la lógica de clasificación verde/amarillo/rojo (LLM + reglas duras) con cuatro frases representativas de distintos niveles de gravedad:

```
(.venv) PS ...\\ParticipantArtifacts> python -m src.decision
```

'Me duele un poco la herida pero es soportable.'

→ AMARILLO (fuente: llm)

Razón: Dolor en la herida que es soportable

'Tengo fiebre desde ayer y la herida está roja e hinchada.'

→ AMARILLO (fuente: llm+reglas)

Razón: Fiebre y signos de posible infección en la herida

'No puedo respirar bien y siento mucho dolor en el pecho.'

→ ROJO (fuente: llm+reglas)

Razón: Dificultad respiratoria y dolor torácico

'Estoy bien, gracias.'

→ VERDE (fuente: llm)

Razón: El paciente reporta sentirse bien

Los dos casos de mayor gravedad (fiebre con signos de infección, y dificultad respiratoria con dolor torácico) quedan marcados con fuente "llm+reglas", confirmando que las reglas duras intervienen como refuerzo del criterio del modelo en los escenarios de mayor riesgo.

5.4 Prueba de integración end-to-end y flujo de despliegue

Se validó que el endpoint POST /turno, que orquesta el ciclo completo (STT → triaje → RAG → TTS), responde con Status 200 de extremo a extremo. La latencia observada en esa corrida (10.05 s) se registró como dato real para el reporte de latencia de la sección 7, y como punto a revisar más adelante para optimización.

Flujo de trabajo de despliegue utilizado durante el desarrollo iterativo:

```
uvicorn server:app --reload --port 8000
```

Ciclo de guardado de cambios en el repositorio:

```
git add .
git commit -m "Descripción de lo que cambiaste"
git push
```

Repositorio: <https://github.com/ValeriaCespedes/tech-sphere-challenge-2026-agente-postop>

6. Demo funcional capturas de pantalla

Capturas tomadas directamente sobre la interfaz de llamada en el navegador (<http://localhost:8000/>), cubriendo los distintos escenarios clínicos y el ciclo completo: hablar, recibir respuesta y ver el resumen estructurado al finalizar.

6.1 Interfaz de llamada primera versión

Primera versión funcional de la interfaz, antes de incorporar el selector de paciente. El paciente reporta dolor en el pecho tras la cirugía y el agente indaga para precisar la sintomatología antes de clasificar.

Llamada de seguimiento

Presiona el botón y habla

 Hablar

 Finalizar y ver resumen

▶ 0:07 / 0:07  

 Tú dijiste: Tengo dolor en el pecho hace dos días después de la cirugía. ¿Qué debo hacer?

 Agente: ¿El dolor es constante o intermitente y ha notado algún otro síntoma como dificultad para respirar, fiebre o sudoración?

6.2 Casos por escenario clínico

Con el selector de paciente ya incorporado, se probaron los cinco escenarios clínicos del dataset (apendicectomía, colecistectomía, cáncer colorrectal, reemplazo de cadera/rodilla, mastectomía/colectomía), cada uno con su propio contexto clínico y flujo de escalación.

Caso rojo colecistectomía. El paciente reporta dolor en el estómago y dificultad respiratoria; el agente escala de inmediato a atención médica sin intentar resolver el síntoma por sí mismo.

Llamada de seguimiento

Paciente:

Jean León Sepúlveda — Colecistectomía (30F, hipertensión) ▼

Presiona el botón y habla

 Hablar

 Finalizar y ver resumen

▶ 0:12 / 0:12  

 Tú dijiste: tengo dolor en el estómago y dificultad respiratoria

 Agente: Lo que me cuenta requiere atención médica inmediata. Voy a escalar esto a nuestro equipo médico ahora mismo y alguien se comunicará con usted a la brevedad. Si los síntomas empeoran, acuda a urgencias de inmediato.

 **Resumen de la llamada**
Paciente: Jean León Sepúlveda
Procedimiento: Colecistectomía
Clasificación final: ROJO
Síntomas reportados: tengo dolor en el estómago y dificultad respiratoria
Referencias usadas: Ninguna
Próximos pasos: Se escaló a atención médica inmediata. Motivo: Dificultad respiratoria y dolor en el estómago pueden ser síntomas de complicaciones graves

Caso verde-apendicectomía. Consulta informativa (alimentación durante la recuperación), respondida con el corpus clínico correspondiente y sin necesidad de escalar.

 **Llamada de seguimiento**

Paciente:
Mauricio Juan González Sánchez — Apendicectomía (34F) ▼

Presiona el botón y habla

 Hablar

 Finalizar y ver resumen

▶ 0:27 / 0:27 🔊 ⋮

 Tú dijiste: ¿Qué alimentos debo evitar mientras me recupero?

 Agente: Durante su recuperación, es importante evitar el consumo de verduras crudas como lechuga y repollo, frutas cítricas o ácidas, carnes enlatadas, salsamentaria, vísceras, alimentos fritos o con mucha grasa, y bebidas alcohólicas o gaseosas. También debe limitar el consumo de lácteos y preferir opciones deslactosadas al inicio. Es fundamental seguir las recomendaciones dietéticas específicas para su caso y consultar con su médico si tiene alguna duda.

 **Resumen de la llamada**
Paciente: Mauricio Juan González Sánchez
Procedimiento: Apendicectomía
Clasificación final: VERDE
Síntomas reportados: ¿Qué alimentos debo evitar mientras me recupero?
Referencias usadas: diagnóstico, tratamiento y seguimiento del paciente adulto con apendicitis aguda en el Hospital Universitario Nacional de Colombia.pdf
Próximos pasos: Recuperación dentro de lo esperado. Continuar con las indicaciones postoperatorias.

Mismo paciente, evolución a caso rojo. Tras reportar fiebre alta (39°) y dolor en el pecho, el agente escala de inmediato citando el motivo clínico.

Paciente:
Mauricio Juan González Sánchez — Apendicectomía (34F) ▼

Presiona el botón y habla

 Hablar

 Finalizar y ver resumen

▶ 0:12 / 0:12 🔊 ⋮

 Tú dijiste: La fiebre ha aumentado a 39 y tengo dolor en el pecho.

 Agente: Lo que me cuenta requiere atención médica inmediata. Voy a escalar esto a nuestro equipo médico ahora mismo y alguien se comunicará con usted a la brevedad. Si los síntomas empeoran, acuda a urgencias de inmediato.

 **Resumen de la llamada**
Paciente: Mauricio Juan González Sánchez
Procedimiento: Apendicectomía
Clasificación final: ROJO
Síntomas reportados: ¿Qué alimentos debo evitar mientras me recupero? | Llevo dos días con fiebre baja como 37.8 | La fiebre ha aumentado a 39 y tengo dolor en el pecho.
Referencias usadas: diagnóstico, tratamiento y seguimiento del paciente adulto con apendicitis aguda en el Hospital Universitario Nacional de Colombia.pdf, Identificación de microorganismos intrabdominales asociados a colección intrabdominal postoperatoria en niños con apendicitis perforada.pdf, FACTORES ASOCIADOS A LA INCIDENCIA DE APENDICITIS AGUDA COMPLICADA EN LA E.S.E. HOSPITAL UNIVERSITARIO DEL CARIBE.pdf
Próximos pasos: Se escaló a atención médica inmediata. Motivo: Fiebre alta de 39 y dolor en el pecho

Caso amarillo. Fiebre baja (37.8°) reportada por el mismo paciente en otro turno: el agente no escala de inmediato, pero registra el caso para seguimiento cercano por el equipo médico, citando las guías de apendicitis complicada que sustentan la decisión.

Paciente:
Mauricio Juan González Sánchez — Apendicectomía (34F) ▼

Presiona el botón y habla

 Hablar  Finalizar y ver resumen

0:07 / 0:25

Tú dijiste: Llevo dos días con fiebre baja como 37.8

Agente: Entiendo que estás experimentando fiebre baja, de 37.8 grados, desde hace dos días. Según el contexto clínico, la fiebre es uno de los síntomas que se deben monitorear después de una apendicitis, especialmente si supera los 38 grados. Te recomiendo consultar con tu médico para evaluar si es necesario tomar alguna medida adicional. Voy a dejar registrado su reporte para que el equipo médico le dé seguimiento.

 Resumen de la llamada
Paciente: Mauricio Juan González Sánchez
Procedimiento: Apendicectomía
Clasificación final: AMARILLO
Síntomas reportados: Llevo dos días con fiebre baja como 37.8
Referencias usadas: Identificación de microorganismos intrabdominales asociados a colección intrabdominal postoperatoria en niños con apendicitis perforada.pdf, diagnóstico, tratamiento y seguimiento del paciente adulto con apendicitis aguda en el Hospital Universitario Nacional de Colombia.pdf, FACTORES ASOCIADOS A LA INCIDENCIA DE APENDICITIS AGUDA COMPLICADA EN LA E.S.E. HOSPITAL UNIVERSITARIO DEL CARIBE.pdf
Próximos pasos: Se registró para seguimiento cercano por el equipo médico. Motivo: Fiebre baja

Caso verde- reemplazo de cadera/rodilla. Consulta sobre tiempos de recuperación, respondida con la guía y el plan casero correspondientes.

 Llamada de seguimiento

Paciente:
Jennifer Camila Arias — Reemplazo de cadera/rodilla (67M, obesidad, diabetes tipo 2) ▼

Presiona el botón y habla

 Hablar  Finalizar y ver resumen

0:27 / 0:27

Tú dijiste: ¿En cuánto tiempo puedo empezar a caminar sin el andador?

Agente: Según su plan de fisioterapia, usted comenzará a caminar inmediatamente después de la cirugía y deberá pensar que usará un andador o bastón durante las primeras 2 a 4 semanas. El tiempo que deberá usar el andador o las muletas es variable y puede ir de varios días a varias semanas. Es importante consultar a su cirujano o fisioterapeuta después de la operación para determinar el mejor momento para dejar de usar los dispositivos de asistencia.

 Resumen de la llamada
Paciente: Jennifer Camila Arias
Procedimiento: Reemplazo de cadera/rodilla
Clasificación final: VERDE
Síntomas reportados: ¿En cuánto tiempo puedo empezar a caminar sin el andador?
Referencias usadas: Reemplazo total de cadera Guía para el paciente .pdf, PLAN CASERO REEMPLAZO TOTAL DE RODILLA.pdf
Próximos pasos: Recuperación dentro de lo esperado. Continuar con las indicaciones postoperatorias.

6.3 Corrección de guardrail: preguntas fuera de alcance clínico

Esta pareja de capturas documenta, sobre la misma paciente y la misma pregunta fuera de dominio ("análisis por voltaje de nodos", un tema de electrónica sin relación con el corpus clínico), el comportamiento antes y después de reforzar el guardrail identificado en la sección 5.1.

Antes: el agente responde la pregunta de electrónica con conocimiento general del modelo, sin anclarla al corpus clínico ni ofrecer escalar comportamiento no deseado para un agente clínico.

 **Llamada de seguimiento**

Paciente:

María Adriana Montoya — Colectomía (52F) ▼

Presiona el botón y habla

 Hablar

 Finalizar y ver resumen

▶ 0:25 / 0:25 🔊 ⋮

 Tú dijiste: ¿Qué es análisis por voltaje de nodos?

Agente: El análisis por voltaje de nodos es un método utilizado para determinar las tensiones en los nodos de un circuito eléctrico, tomando como referencia un nodo común, y se basa en la aplicación de la Ley de Corrientes de Kirchhoff y la Ley de Ohm. Este método permite relacionar voltajes, corrientes y resistencias de manera eficiente. Si necesitas más información específica, te recomiendo que consultes con un profesional en ingeniería eléctrica.

 **Resumen de la llamada**
Paciente: María Adriana Montoya
Procedimiento: Colectomía
Clasificación final: VERDE
Síntomas reportados: ¿Qué es análisis por voltaje de nodos?
Referencias usadas: Informe 2 laboratorio Circuitos.pdf
Próximos pasos: Recuperación dentro de lo esperado. Continuar con las indicaciones postoperatorias.

Después: ante la misma pregunta, el agente reconoce que no hay información disponible en el contexto clínico y ofrece derivar a un especialista, en lugar de improvisar una respuesta.

 **Llamada de seguimiento**

Paciente:

María Adriana Montoya — Colectomía (52F) ▼

Presiona el botón y habla

 Hablar

 Finalizar y ver resumen

⏸ 0:04 / 0:20 🔊 ⋮

 Tú dijiste: ¿Qué es análisis por voltaje de nodo?

Agente: Lo siento, pero no hay información disponible en el contexto clínico proporcionado sobre "análisis por voltaje de nodo". Si necesita más información o aclaraciones sobre su diagnóstico o tratamiento, le recomiendo que hable con su médico para obtener una respuesta más precisa y personalizada. ¿Desea que lo derive con un especialista para obtener más información?

 **Resumen de la llamada**
Paciente: María Adriana Montoya
Procedimiento: Colectomía
Clasificación final: VERDE
Síntomas reportados: ¿Qué es análisis por voltaje de nodo?
Referencias usadas: GUÍA DE MANEJO PARA EL DIAGNÓSTICO, TRATAMIENTO, SEGUIMIENTO Y PALIACIÓN DEL CÁNCER DE COLÓN Y RECTO.pdf
Próximos pasos: Recuperación dentro de lo esperado. Continuar con las indicaciones postoperatorias.

7. Métricas de rendimiento

Métricas calculadas sobre 17 llamadas de prueba (28 turnos totales) durante el desarrollo, mediante el script scripts/calcular_metricas.

```
(.venv) PS C:\Users\valer\Desktop\ParticipantArtifacts> python -m scripts.calcular_metricas

=== LATENCIA (segundos, desde que termina de hablar el paciente hasta que suena el audio) ===
P50: 11.56s
P95: 22.58s
Mínima: 4.22s | Máxima: 24.31s

=== DESGLOSE PROMEDIO POR ETAPA ===
STT (transcripción): 0.75s promedio
LLM (RAG + razonamiento): 0.65s promedio
TTS (síntesis de voz): 10.41s promedio

=== CONSUMO DE TOKENS ===
Tokens de entrada por turno – promedio: 1295 | total: 36272
Tokens de salida por turno – promedio: 89 | total: 2495

=== INVOCACIONES AL MODELO ===
Invocaciones al LLM por turno: 2 (clasificación de triaje + generación de respuesta)

=== CONSULTAS AL RAG ===
Consultas al RAG por llamada – promedio: 1.6
(1 consulta de retrieval por turno, dentro de responder_con_contexto)

=== COSTO ESTIMADO POR LLAMADA ===
(Nota: esto NO incluye el costo de clasificación de triaje, que es una
segunda llamada al LLM por turno – multiplicar aprox. x2 para estimación conservadora)
Turnos promedio por llamada: 1.6
Costo por turno (solo respuesta RAG): $0.00083 USD
Costo estimado por llamada (solo respuesta RAG): $0.00137 USD
Costo estimado por llamada (incluyendo triaje, x2 aprox.): $0.00275 USD

Precios usados: Groq Llama 3.3 70B Versatile –
$0.59/M tokens entrada, $0.79/M tokens salida
```

Métrica	Valor
Latencia P50 (fin de habla → inicio de audio del agente)	11.56 s
Latencia P95	22.58 s
Latencia mínima / máxima observada	4.22 s / 24.31 s
Desglose promedio — STT (transcripción, Whisper Large V3)	0.75 s
Desglose promedio — LLM (RAG + razonamiento, Llama 3.3 70B)	0.65 s
Desglose promedio — TTS (síntesis de voz, Kokoro)	10.41 s
Tokens de entrada por turno (promedio / total)	1,295 / 36,272
Tokens de salida por turno (promedio / total)	89 / 2,495
Invocaciones al LLM por turno	2 (clasificación de triaje + generación de respuesta)
Consultas al RAG por llamada (promedio)	1.6
Costo estimado por llamada	\$0.00275 USD

Precios usados para el costo estimado: Groq, Llama 3.3 70B Versatile \$0.59 USD por millón de tokens de entrada, \$0.79 USD por millón de tokens de salida (verificado en groq.com/pricing). El costo por llamada incluyendo triaje (dos invocaciones al LLM por turno) se estima, de forma conservadora, en \$0.00275 USD.

El desglose por etapa muestra que TTS (Kokoro en CPU) concentra la mayor parte de la latencia total (~10.41 s de los ~11.56 s de P50), muy por encima de STT (0.75 s) y del LLM (0.65 s). Es, por lo tanto, el cuello de botella principal del pipeline.

8. Limitaciones conocidas y trabajo futuro

- Sin memoria entre llamadas distintas: el historial conversacional se mantiene dentro de una misma llamada (`llamada_id`), pero no persiste entre sesiones separadas del mismo paciente.
- Retrieval por similitud pura: el filtro por escenario clínico mitiga el ruido de documentos ajenos, pero al no haber re-ranking, documentos cortos y específicos (p. ej. planes de cuidado de una página) pueden perder frente a papers largos en casos límite.
- Latencia de TTS: Kokoro en CPU es el cuello de botella principal (sección 7). Con más tiempo de desarrollo, se evaluaría Piper como alternativa más rápida.
- La longitud de algunas respuestas generadas por el LLM aún puede resultar larga para un canal de voz (nota registrada en la sección 5.2); queda como ajuste de prompt pendiente.